基于flink的
电商用户行为数据分析

讲师：武晟然

主要内容

- 批处理和流处理
- 电商用户行为分析
- 数据源解析
- 项目模块划分

批处理和流处理

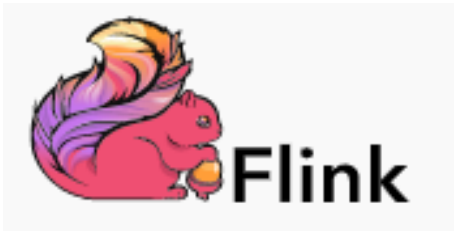

批处理

- 批处理主要操作大容量静态数据集，并在计算过程完成后返回结果。

  可以认为，处理的是用一个固定时间间隔分组的数据点集合。批处理模式中使用的数据集通常符合下列特征：

  - 有界：批处理数据集代表数据的有限集合
  - 持久：数据通常始终存储在某种类型的持久存储位置中
  - 大量：批处理操作通常是处理极为海量数据集的唯一方法

流处理

- 流处理可以对随时进入系统的数据进行计算。流处理方式无需针对整个数据集执行操作，而是对通过系统传输的每个数据项执行操作。流处理中的数据集是“无边界”的，这就产生了几个重要的影响：
  - 可以处理几乎无限量的数据，但同一时间只能处理一条数据，不同记录间只维持最少量的状态
  - 处理工作是基于事件的，除非明确停止否则没有“尽头”
  - 处理结果立刻可用，并会随着新数据的抵达继续更新。

电商用户行为分析

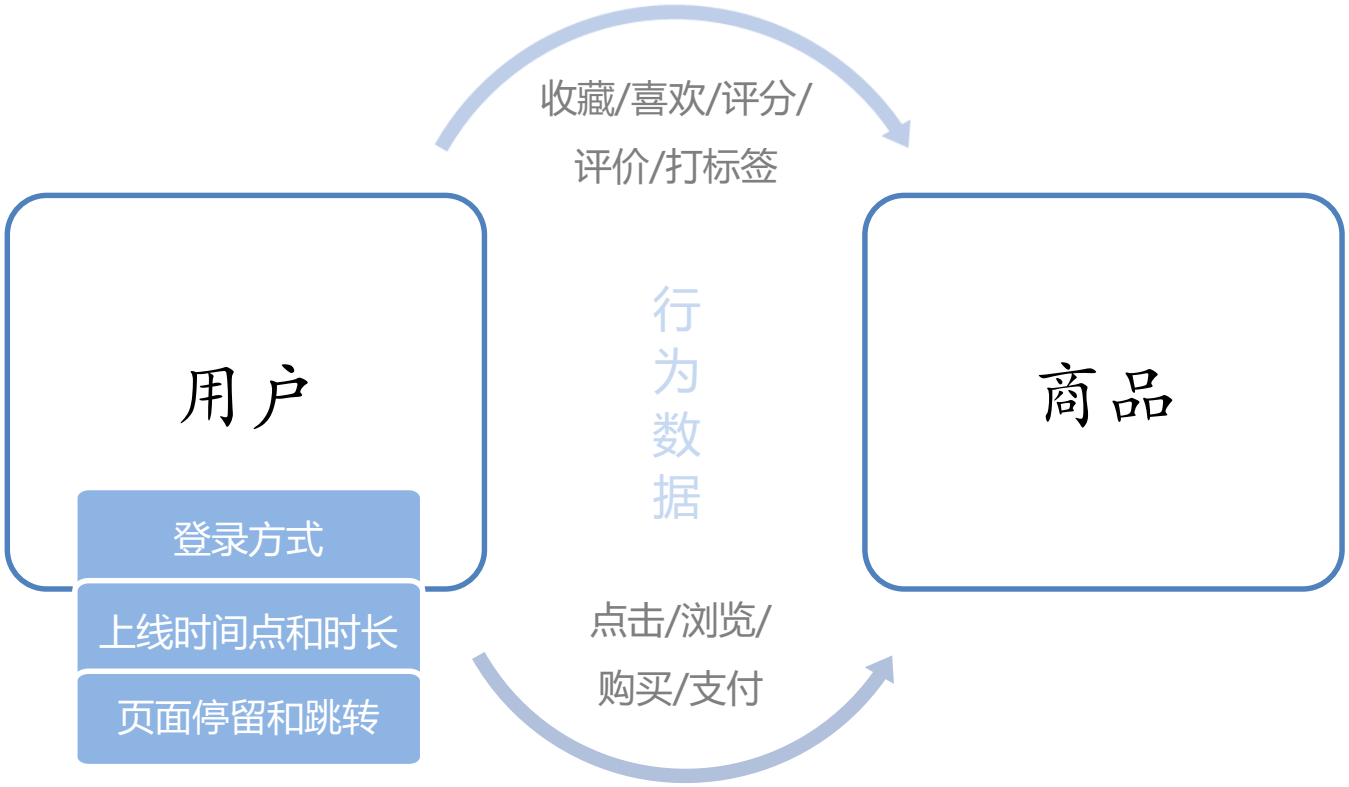

电商用户行为分析

- 统计分析
  - 点击、浏览
  - 热门商品、近期热门商品、分类热门商品，流量统计
- 偏好统计
  - 收藏、喜欢、评分、打标签
  - 用户画像，推荐列表（结合特征工程和机器学习算法）
- 风险控制
  - 下订单、支付、登录
  - 刷单监控，订单失效监控，恶意登录（短时间内频繁登录失败）监控

电商用户行为分析——项目模块设计

实时统计分析

- 实时热门商品统计
- 实时热门页面流量统计
- 实时访问流量统计
- APP 市场推广统计
- 页面广告点击量统计

业务流程及风险控制

- 页面广告黑名单过滤
- 恶意登录监控
- 订单支付失效监控

电商用户行为分析——项目模块设计

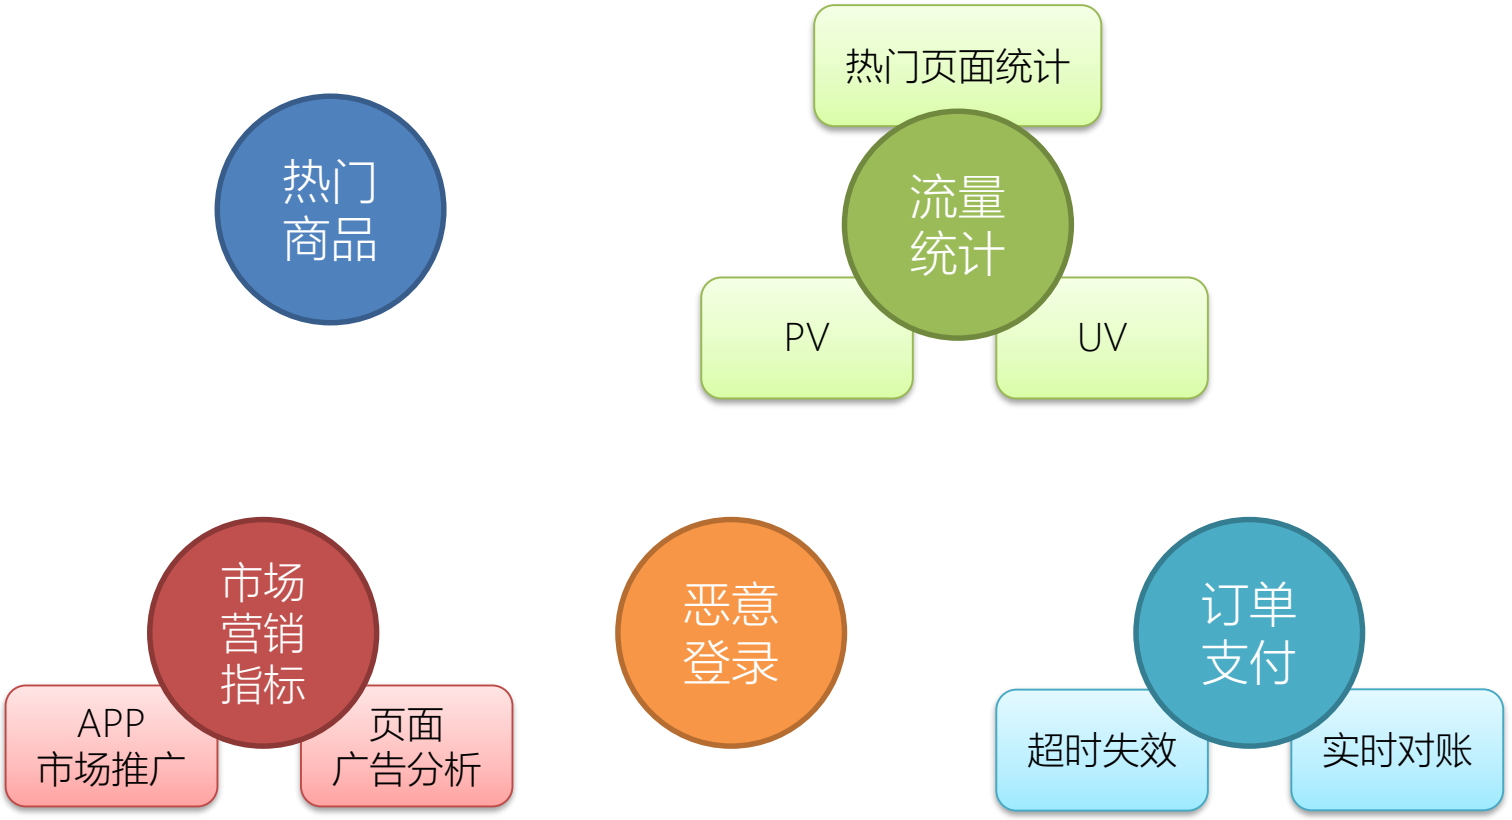

数据源解析

- 用户行为数据

UserBehavior.csv

e.g. 543462, 1715, 1464116, pv, 1511658000

- web 服务器日志

apache.log

e.g. 66.249.73.135 - - 17/05/2015:10:05:40 +0000 GET /blog/tags/ipv6

数据源解析

- 数据结构 —— UserBehavior

字段名	数据类型	说明
userId	Long	加密后的用户ID
itemId	Long	加密后的商品ID
categoryId	Int	加密后的商品所属类别ID
behavior	String	用户行为类型，包括('pv', ''buy, 'cart', 'fav')
timestamp	Long	行为发生的时间戳，单位秒

数据源解析

- 数据结构 —— ApacheLogEvent

字段名	数据类型	说明
ip	String	访问的 IP
userId	Long	访问的 user ID
eventTime	Long	访问时间
method	String	访问方法 GET/POST/PUT/DELETE
url	String	访问的 url

项目模块

- 实时热门商品统计
- 实时流量统计
- 恶意登录监控
- 订单支付失效监控

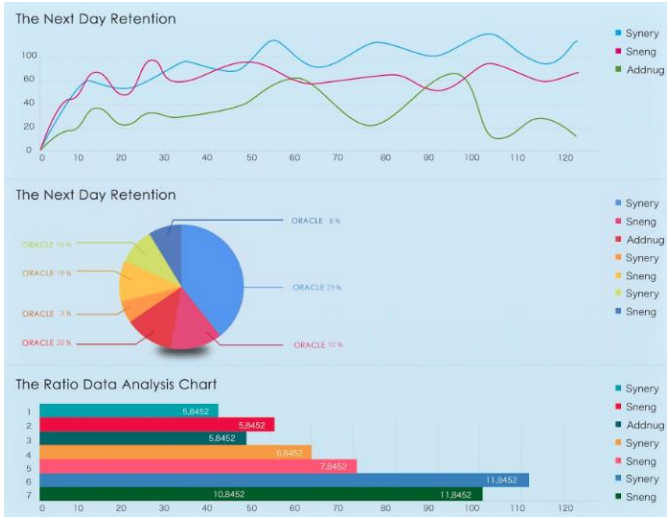

热门实时商品统计

- 基本需求
  - 统计近1小时内的热门商品，每5分钟更新一次
  - 热门度用浏览次数（“pv”）来衡量
- 解决思路
  - 在所有用户行为数据中，过滤出浏览（“pv”）行为进行统计
  - 构建滑动窗口，窗口长度为1小时，滑动距离为5分钟

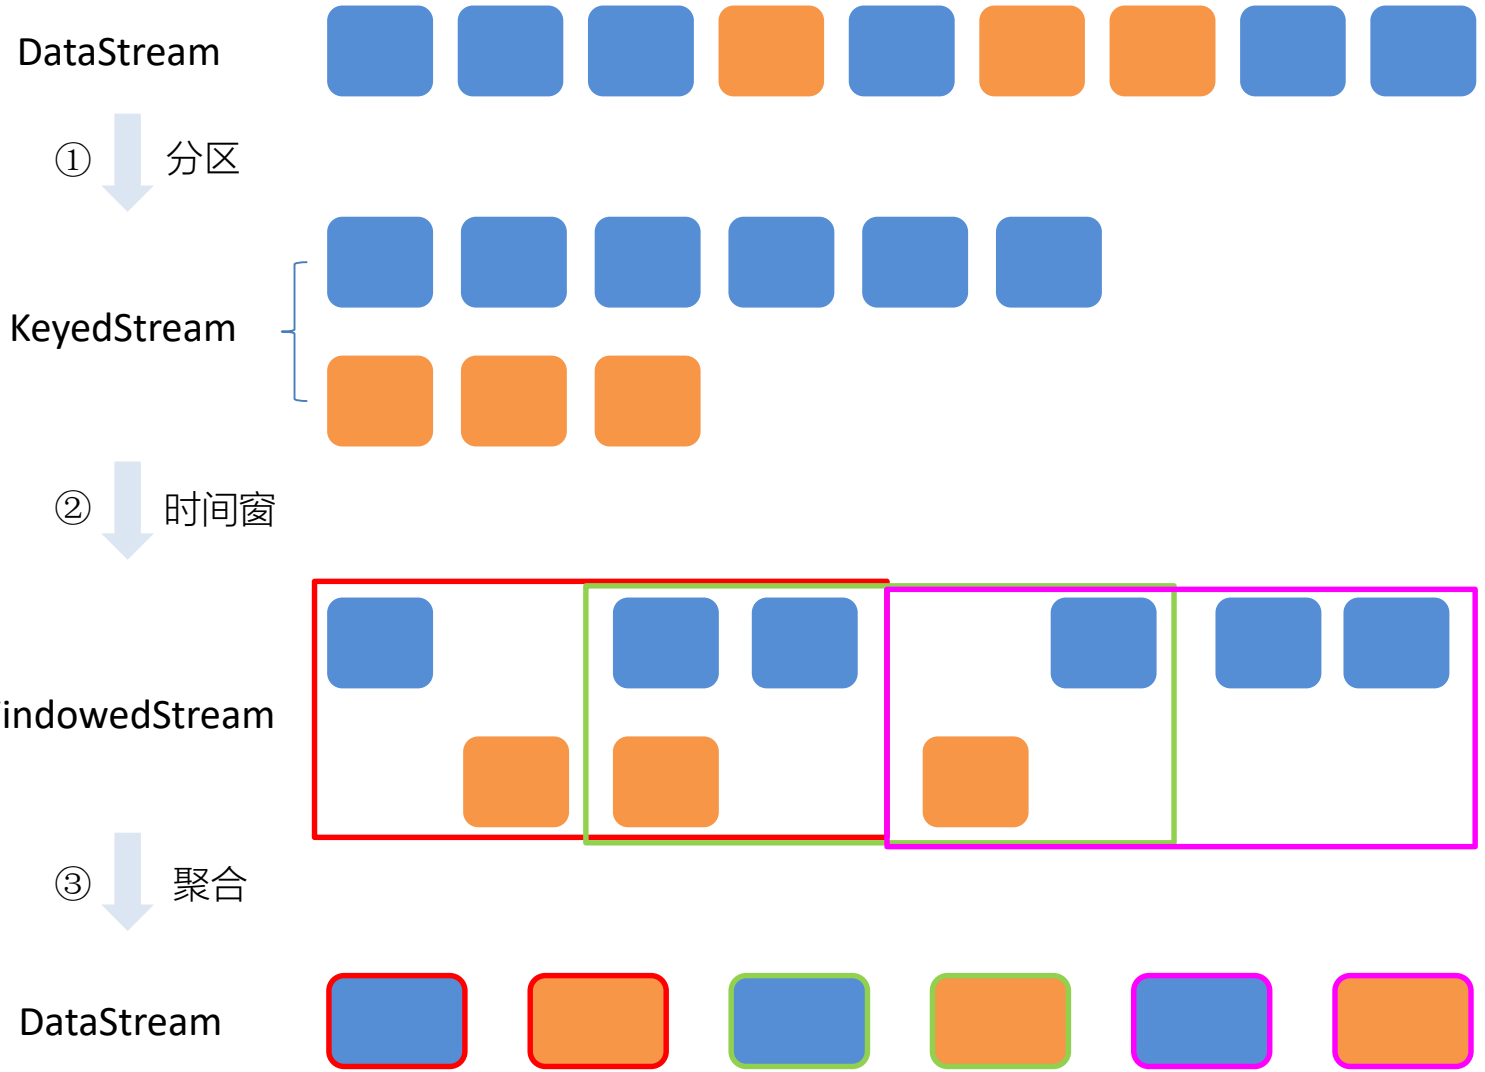
DataStream
①
分区
KeyedStream
②
时间窗
WindowedStream
③
聚合
DataStream

热门实时商品统计

- 按照商品Id进行分区

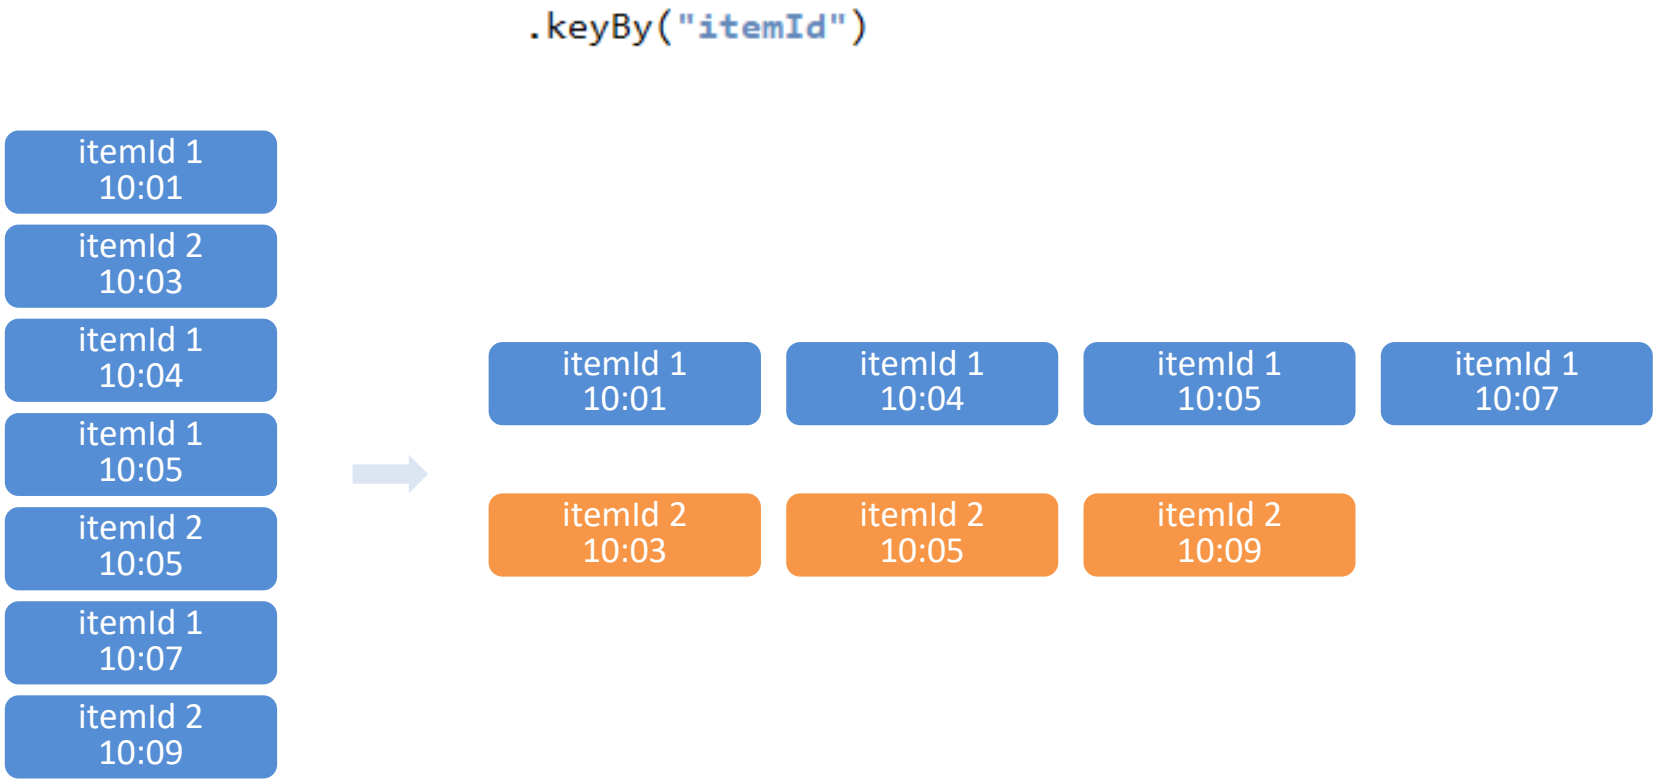

热门实时商品统计

- 设置时间窗口

```
.timeWindow(Time.minutes(60), Time.minutes(5))
```

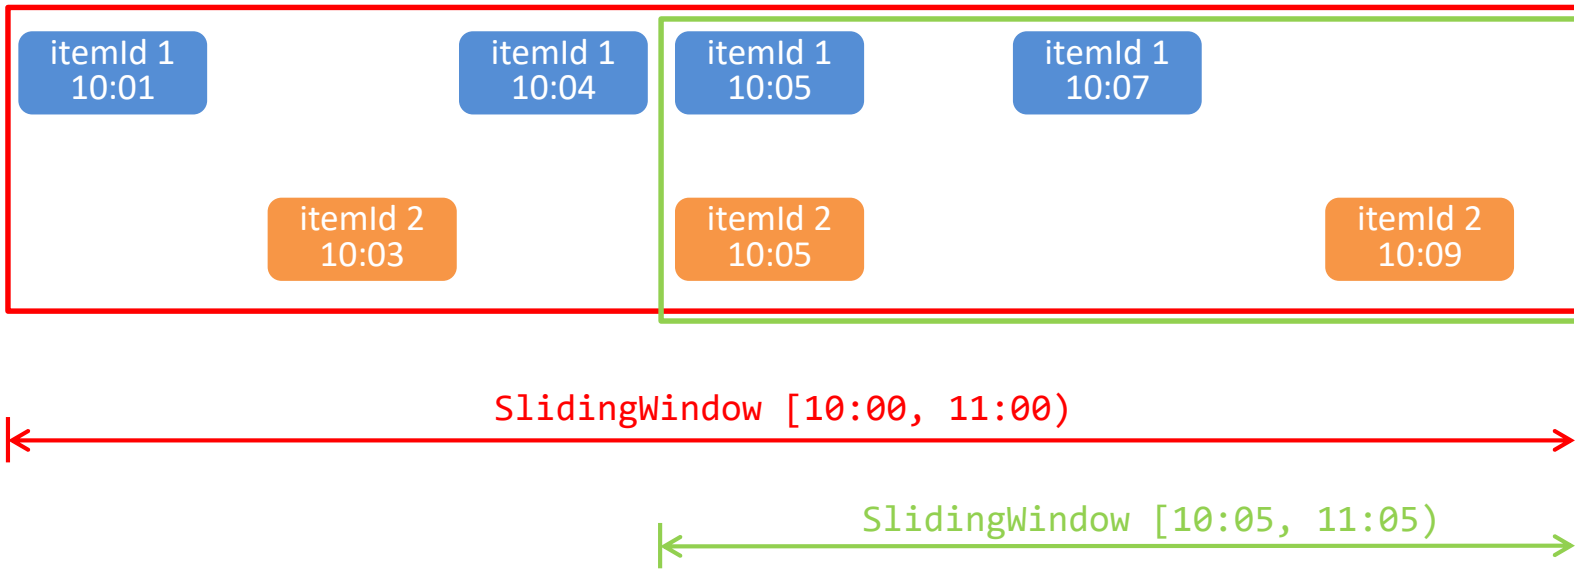

热门实时商品统计

- 时间窗口（timeWindow）区间为左闭右开
- 同一份数据会被分发到不同的窗口

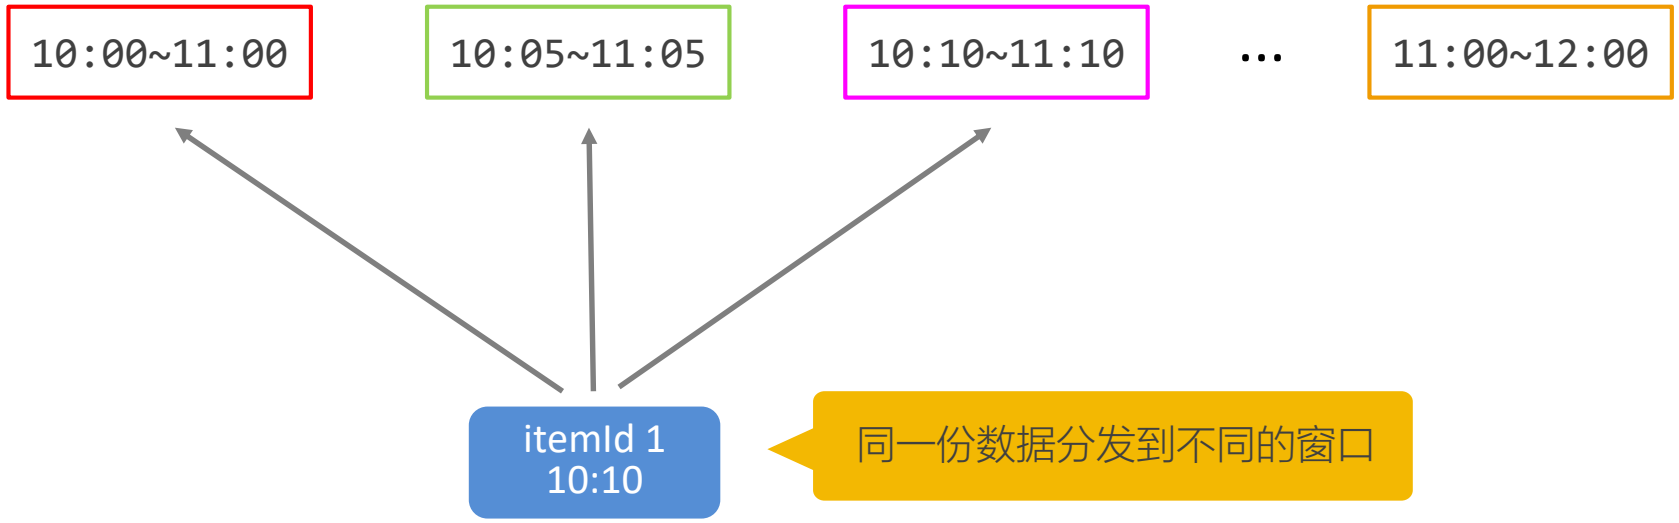

热门实时商品统计

- 窗口聚合

```
.aggregate(new CountAgg(), new WindowResultFunction())
```

定义窗口聚合规则

定义输出数据结构

ItemViewCount(itemId, windowEnd, count)

WindowedStream → DataStream<*ItemViewCount*>

热门实时商品统计

- 窗口聚合策略——每出现一条记录就加一

```
class CountAgg extends AggregateFunction[UserBehavior, Long, Long] {

  override def createAccumulator(): Long = 0L

  override def add(userBehavior: UserBehavior, acc: Long): Long = acc + 1

  override def getResult(acc: Long): Long = acc

  override def merge(acc1: Long, acc2: Long): Long = acc1 + acc2
}
```

- 累加规则——窗口内碰到一条数据就加一（add方法）
- 实现 AggregateFunction 接口
  - interface AggregateFunction<IN, ACC, OUT>

热门实时商品统计

- 定义输出结构 —— ItemViewCount(itemId, windowEnd, count)
- 实现 WindowFunction 接口
  - trait WindowFunction[IN, OUT, KEY, W <: Window]
    - IN: 输入为累加器的类型，Long
    - OUT: 窗口累加以后输出的类型为 ItemViewCount(itemId: Long, windowEnd: Long, count: Long), windowEnd为窗口的结束时间，也是窗口的唯一标识
    - KEY: Tuple泛型，在这里是 itemId，窗口根据itemId聚合
    - W: 聚合的窗口，w.getEnd 就能拿到窗口的结束时间
    - override def apply

```
override def apply(key: Tuple, window: TimeWindow, aggregateResult: Iterable[Long],
                   collector: Collector[ItemViewCount]) : Unit = {
  val itemId: Long = key.asInstanceOf[Tuple1[Long]].f0
  val count = aggregateResult.iterator.next
  collector.collect(ItemViewCount(itemId, window.getEnd, count))
}
```

热门实时商品统计

- 窗口聚合示例

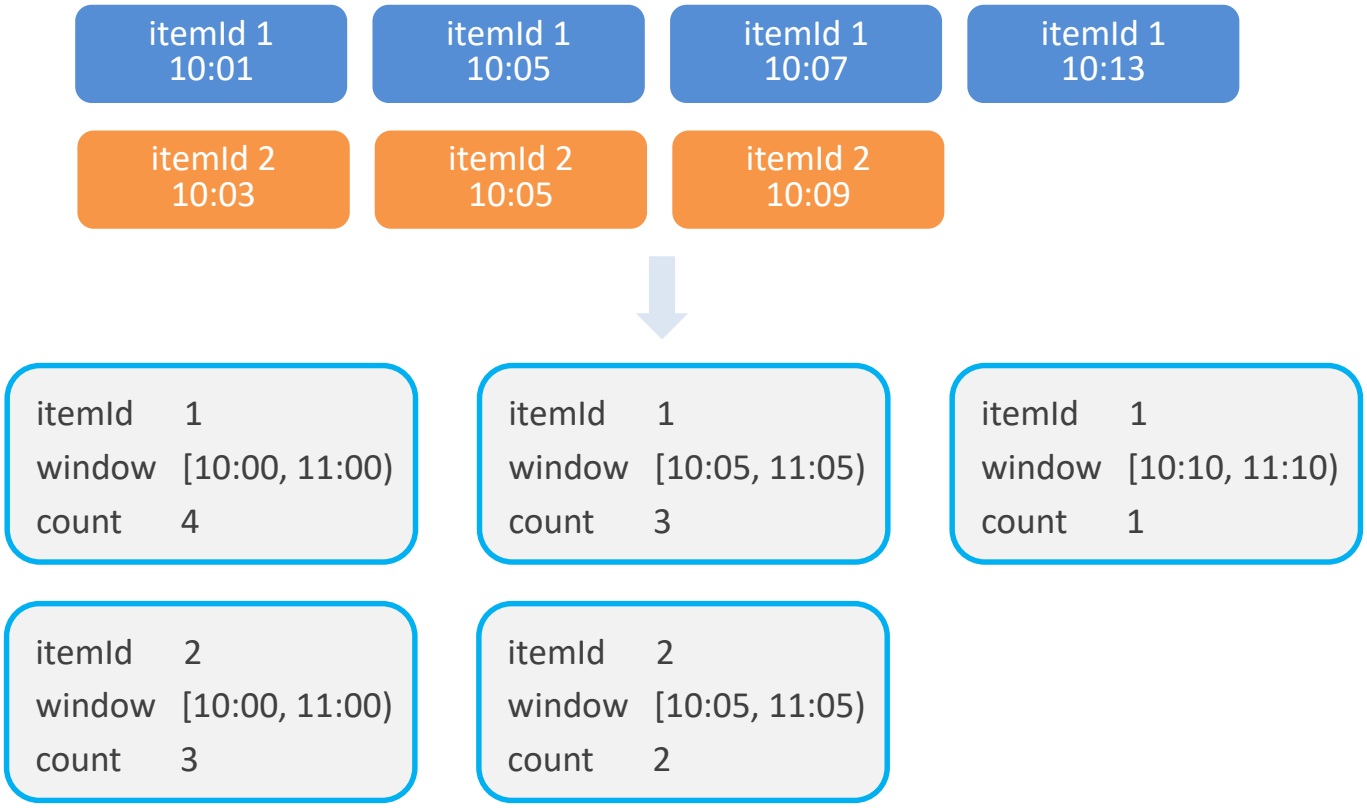

热门实时商品统计

- 进行统计整理 —— keyBy(“windowEnd”)

itemId	1
window	[10:00, 11:00)
count	4

itemId	1
window	[10:05, 11:05)
count	3

itemId	1
window	[10:10, 11:10)
count	1

itemId	2
window	[10:00, 11:00)
count	3

itemId	2
window	[10:05, 11:05)
count	2

热门实时商品统计

- 状态编程

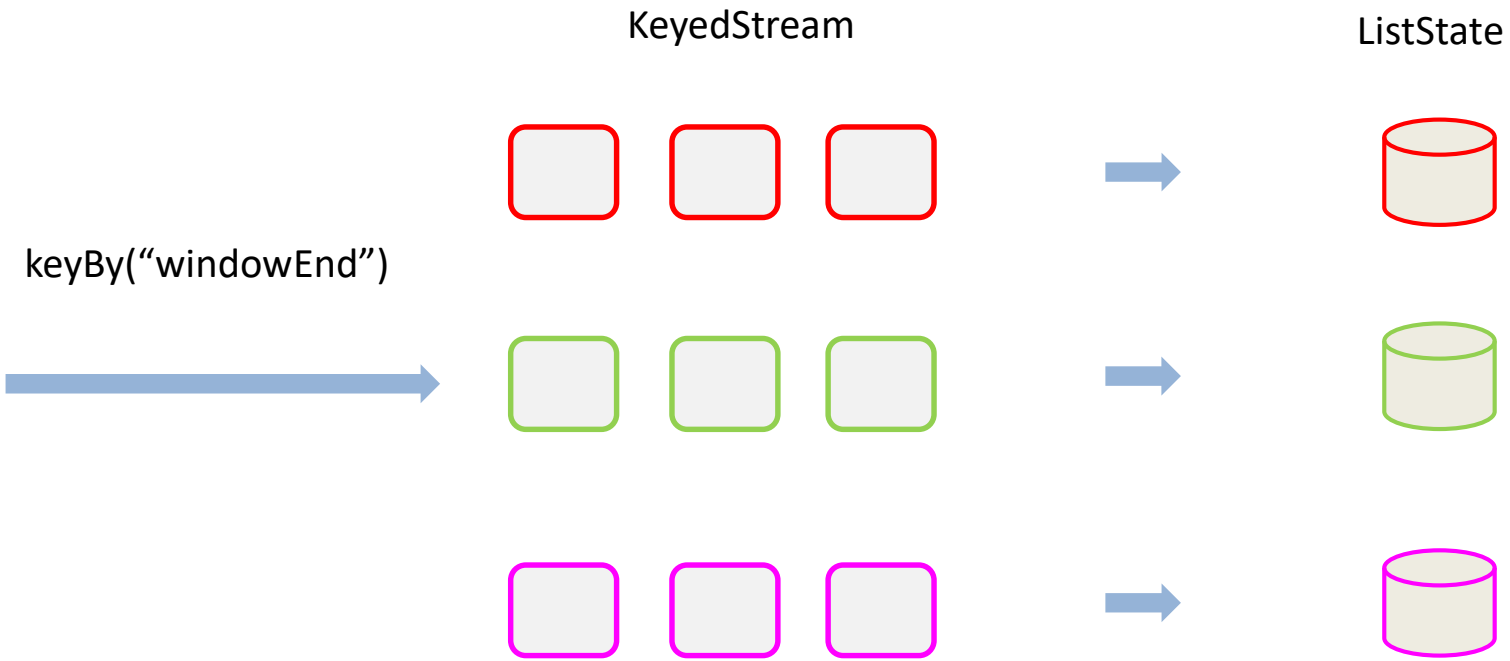

热门实时商品统计

- 最终排序输出 —— keyedProcessFunction
  - 针对有状态流的底层API
  - KeyedProcessFunction 会对分区后的每一条子流进行处理
  - 以 windowEnd 作为 key，保证分流以后每一条流的数据都在一个时间窗口内
  - 从 ListState 中读取当前流的状态，存储数据进行排序输出

热门实时商品统计

- 用 ProcessFunction 来定义 KeyedStream 的处理逻辑
- 分流之后，每个 KeyedStream 都有其自己的生命周期
  - open：初始化，在这里可以获取当前流的状态
  - processElement：处理流中每一个元素时调用
  - onTimer：定时调用，注册定时器 Timer 并触发之后的回调操作

热门实时商品统计

定时器触发时，相当于收到了大于 windowEnd + 100 的 watermark，可以认为这时窗口已经收集到了所有数据，从 ListState 中读取进行处理

实时流量统计 —— 热门页面

- 基本需求
  - 从web服务器的日志中，统计实时的热门访问页面
  - 统计每分钟的ip访问量，取出访问量最大的5个地址，每5秒更新一次
- 解决思路
  - 将 apache 服务器日志中的时间，转换为时间戳，作为 Event Time
  - 构建滑动窗口，窗口长度为1分钟，滑动距离为5秒

实时流量统计 —— PV 和 UV

- 基本需求
  - 从埋点日志中，统计实时的 PV 和 UV
  - 统计每小时的访问量（PV），并且对用户进行去重（UV）
- 解决思路
  - 统计埋点日志中的 pv 行为，利用 Set 数据结构进行去重
  - 对于超大规模的数据，可以考虑用布隆过滤器进行去重

市场营销分析 —— APP 市场推广统计

- 基本需求
  - 从埋点日志中，统计 APP 市场推广的数据指标
  - 按照不同的推广渠道，分别统计数据
- 解决思路
  - 通过过滤日志中的用户行为，按照不同的渠道进行统计
  - 可以用 process function 处理，得到自定义的输出数据信息

市场营销分析 —— 页面广告统计

- 基本需求
  - 从埋点日志中，统计每小时页面广告的点击量，5秒刷新一次，并按照不同省份进行划分
  - 对于“刷单”式的频繁点击行为进行过滤，并将该用户加入黑名单
- 解决思路
  - 根据省份进行分组，创建长度为1小时、滑动距离为5秒的时间窗口进行统计
  - 可以用 process function 进行黑名单过滤，检测用户对同一广告的点击量，如果超过上限则将用户信息以侧输出流输出到黑名单中

恶意登录监控

- 基本需求
  - 用户在短时间内频繁登录失败，有程序恶意攻击的可能
  - 同一用户（可以是不同IP）在2秒内连续两次登录失败，需要报警
- 解决思路
  - 将用户的登录失败行为存入 ListState，设定定时器2秒后触发，查看 ListState 中有几次失败登录
  - 更加精确的检测，可以使用 CEP 库实现事件流的模式匹配

订单支付实时监控

- 基本需求
  - 用户下单之后，应设置订单失效时间，以提高用户支付的意愿，并降低系统风险
  - 用户下单后15分钟未支付，则输出监控信息
- 解决思路
  - 利用 CEP 库进行事件流的模式匹配，并设定匹配的时间间隔
  - 也可以利用状态编程，用 process function 实现处理逻辑

订单支付实时对账

- 基本需求
  - 用户下单并支付后，应查询到账信息，进行实时对账
  - 如果有不匹配的支付信息或者到账信息，输出提示信息
- 解决思路
  - 从两条流中分别读取订单支付信息和到账信息，合并处理
  - 用 connect 连接合并两条流，用 coProcessFunction 做匹配处理

Q & A